

## Paper summary

AI VISION Lab

1. 공부한 논문의 제목, 게재된 학회 혹은 저널 등 논문 기본 정보를 적으세요.
  - A. 이름: Extracting and Composing Robust Features with Denoising Autoencoders
  - B. 저널: ICML
  - C. 도메인: Denoising Autoencoder
  - D. 출판 연도: 2008
  - E. 저자: Pascal Vincent et al.
2. 논문에서 제안한 알고리즘 및 프레임워크에 대해 본인이 이해한대로 다이어그램을 그려보세요. **논문 Figure를 그대로 따라 그리면 안됩니다.**
  - A. [선행연구] Deep Architecture를 구성할 때, 성능이 떨어지는 문제가 발생함 (원인: Gradient Vanishing/Exploding)
  - B. [선행연구] 이를 해결하는 좋은 방법은 Unsupervised 방식으로 layer wise하게 initialization하는 것. (e.g.,  $X \rightarrow H$  가 있다면,  $X$ 의 다음 Layer인  $H$ 만을 가지고  $X$ 를 초기화)  $\rightarrow$  결과적으로 학습이 불안정한 문제가 해결되는 결과를 가져왔음.
  - C. 해당 과정에서 논문의 저자는, 중간 표현 (intermediate Representation)의 존재에 대한 고민을 함 (?)
  - D. 대체 강건한 중간 표현이란 무엇이며, 중간 표현을 평가하는 기준으로는 어떤 점이 있을까?
  - E. 저자는 중간표현의 기준을 제시하고
    - i. Input에 대한 정보 유지
    - ii.  $X$ 를 그대로(identity)하게 받아오는 것이 아닌, 제약(Constraint)이 존재
    - iii. 희소표현 (0 or 1)
  - F. 강건한 중간표현을 구하기 위한 실험을 설계함 = DAE(Denoising AE)

- G.  $X$ : Input,  $f_{\theta}(X) = Y = W * X + b$ ,  $g_{\theta'}(Y) = Z = W^T * Y + b'$ . 이때,  $g_{\theta'}/W^T$  는  $f_{\theta}/W$  Transpose(tied weight) 가 기본적인 AE의 구조라면, DAE는  $X$ 를 그대로 Input으로 이용하는 것이 아닌,  $\hat{X}$ 를 Input으로 이용함 (이때,  $\hat{X}$ 는  $X$ 에 noise를 더해주는 구조가 아닌, random하게 선택한  $X$ 의 element를 0으로 변경해주는 식으로 처리함)
- H. DAE model의 확률적 표현방식은 다음과 같음
- I.  $q^0(X, \hat{X}, Y)$ 이고 이는  $q^0(x) * q_D(\hat{X}|X) * q^0(Y|\hat{X})$ 로 전개됨. 이때,  $q^0(Y|\hat{X}) = \delta_{f_{\theta}(\hat{X})}(Y)$ 로 수정가능. ( $\delta$ 의 경우,  $Y = \hat{X}$  Return 1 else 0)  
( $Y = \text{label}$ , 결정적인 존재이므로 수정가능)
- J. 이처럼, 표현할 수 있다는 점에서 Robust하다고 볼 수 있으며, 효과적인 denoising 과정을 보여줬다는 점에서 의의가 있음.
- K. 추가적으로 Manifold Learning과의 상관관계를 확인했을 때,  $\hat{X}$ 는 noisy하므로, Manifold 밖, 혹은 매우 낮은 확률을 가진 값이라고 볼 수 있음.  
따라서,  $q_D(\hat{X}|X)$ 를 처리해주는 과정은 Manifold Learning과 유사하다고 볼 수 있음.
3. 본인이 생각하는 이 논문의 장점이 무엇이라고 생각하나요? **논문 Contribution bullet을 그대로 따라 적으면 안됩니다.**
- A. Robust함을 확인하려고 시작해서, AE의 한계였던  $X$ 의 중간표현으로의 전달을 Robust하게 표현하는데 성공했다는 것 또한 우수하다고 할 수 있으나, 개인적으로는 Denoising, Manifold로의 확장까지 기여했다는 점이 이 논문의 가장 큰 장점이라고 생각함
4. 이 논문을 읽으면서 느낀 점, 혹은 배운 점이 있으면 적어보세요.
- A. 새로운 가설에 대해서 다양한 이론에 적용하는 과정. 또한, DAE에 대해서 다루다가 갑자기 등장하는 Manifold에서 Diffusion뿐만 아니라, 넓은 범위에서의 학습의 필요성에 대해서 다시한번 배울 수 있었음.
5. 이 논문의 한계점이 있다면 무엇이라고 생각하나요?
- A. 수식을 간단하게 표현할 수 있었던 이유이자,  $q^0$ 에 대해서 전개할 때,  $z$ 를 condition으로 사용하지 않을 수 있었던 이유는 tied weight기 때문임. 즉

이는  $y \rightarrow z$ 과정을 deterministic(+ 간결함)하게 처리할 수 있도록 만들었으나, Generative model의 설계 측면에서 생각해 보자면, Probability하지 않기 때문에 다양성 측면에서 한계를 가지고 있음이 분명함 (이후 나온 VAE에서는 Z를 Condition으로 사용해서 한계를 해결)

6. 본인의 연구에 접목시켜볼 점이 있을지 생각하고 적어보세요.

A. Diffusion 선행 논문

7. 본 Summary를 작성하는 과정에서 생성형AI를 사용했나요?

A. 아니요

날짜: 2025-06-25

이름: 신준원



2025. 6. 25 수요일 A connection Between Gcore matching & Denoising Autoencoder

Denoising Autoencoder 소개

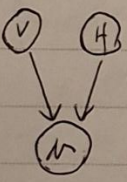
Previous work ~~이름~~ (class: Y, data: X)

Generative (ex. GPT)  $\rightarrow$  전리파일을 복제하는  $\rightarrow p_{data} \rightarrow p_{model}$   
 Discriminative (ex. GVM)  $\rightarrow p(Y/X)$

$\rightarrow$  전리 unsupervised 판별기, input 은 중간표현 (intermediate representation)



Deep Architecture 의 어려움

①   $\rightarrow V, H$  의 relation 을 정확히 파악 가능한다면  
 $H, N$  의 관계를 부정확한 것만 알 수 있음 (explaining away)


또한, 해당 graphical model 은 깊게 생각하면 난이도 4

② hidden layer 1~2 개를 넣는 경우  $\rightarrow$  optimization 의 어려움  
 unsupervised pretrain

①, ② 문제점  $\rightarrow$  중간표현 (latent space) 의 등장으로 해결

ex. training belief net, stacked Autoencoder

③ local optimization (fully-connected 2개 layer)



input layer  $\rightarrow$  hidden layer

end-to-end  $\Rightarrow$  gradient vanishing 문제  
 $\rightarrow$  local optimization 문제.

$x_1, x_2, x_3 \rightarrow [h_1, h_2]$  ↑  $\approx$  기반!

poor solution 방지

$\rightarrow$  local!  $\rightarrow$  fine-tune 진행 (확정)  
 with label

unsupervised



무엇이 해답정답을 통해 얻는 것인가?

Unsupervised 가 좋은 결과 (공간 표현)을 만들어 내지만 "어떻게?"

→ RBN, Autoencoder 의 하위 단계에서 동작 중

이 문제에서는 좋은 공간 표현에 대한 명시적 기준이 이기함.

→ 원본의 정보 보유 → 정보 유지

→ 의미 (각 vector 들...) ①, ② 클라

→ 희소 표현 (sparsity representation) - 주파리

→ 공간 표현이 - input에 대한 정보를 가진다면 with AE.

→ input + noise (노이즈)에 대한 정보를 입력시 비슷한 결과를 얻을 것이다.

### Algorithm (DAE)

notation:  $E_{p(x)} [f(x)] = \int p(x) f(x) dx$   
Expectation:

Entropy:  $H(x) = H(p) = E_{p(x)} [-\log p(x)]$

Conditional Entropy:  $H(x|y) = E_{p(x,y)} [-\log p(x|y)]$

KL-divergence:  $D_{KL}(p||q) = E_{p(x)} [\log \frac{p(x)}{q(x)}]$

Cross entropy:  $H(p||q) = E_{p(x)} [-\log q(x)] = H(p) + D_{KL}(p||q)$


Mutual information:  $I(x;y) = H(x) - H(x|y)$

Sigmoid:  $S(x) = \frac{1}{1 + e^{-x}}$ ,  $(\Rightarrow S(x) = (S(x_1), \dots, S(x_n))^T$

Bernoulli distribution:  $\mu: B_n(x) = (B_{n_1}(x_1), \dots, B_{n_d}(x_d))$

④ ~~결과~~,  $p(x, t) = p(A) \cdot p(t)$  ~~타당~~  
①

# Basic Autoencoder



가중치 쌍  
tied weight  
 $w^T = w'$

$$y = \underset{f_\theta}{s}(w x + b) \quad , \quad z = \underset{f_{\theta'}}{s}(w' y + b') \quad , \quad s = \text{sigmoid.}$$

$$\theta = [w, b] \quad \theta' = [w', b']$$

$$\text{optimizer} = \arg \min_{\theta, \theta'} \frac{1}{n} \sum_{i=1}^n \boxed{L(x^{(i)}, z^{(i)})} \xrightarrow{f(f(x))}$$

$$\text{Loss} = L(x^i, z^i) = \|x - z\|^2 \quad \begin{matrix} \text{연속 분포} \\ \text{(general한 상황)} \end{matrix}$$

$$\text{Loss}_H = - \sum_{k=1}^d [x_k \log z_k + (1-x_k) \log (1-z_k)] \quad \begin{matrix} \text{이산 분포} \\ \text{(베르누이, (0,1))} \end{matrix}$$

identity mapping  $\rightarrow$  한계점

x 구조를 그대로 복원 하는 문제가 발생하기도 함.

$\rightarrow$  Robust 해의 필요  $\rightarrow$  x 중  $x_1$  양자화하여 복원은 강제함 (DAE)




# Denoising Autoencoder

1. 입력의 AE 과정  $\tilde{x}$   $\rightarrow$   $\sim q_D(\tilde{x}|x)$  이고  $\rightarrow$   $\tilde{x}$ 에 대해 random하게 0으로 처리 나머지는 그대로 유지

이후  $\tilde{x}$ 의 예측 = 변환 (0으로 변환된 부분) 채우기

$\rightarrow$  input  $\tilde{x}$  /  $Loss_H(x, \hat{x})$



Additional notation.  $g^0(x) \rightarrow$   $x$ 는  $\pm$  (test-target) input에 대한 분포  
 $f_{f(0)}(\tilde{x})|y \rightarrow$  deterministic한 경우  $\rightarrow$  1 or 0 return  
 $\rightarrow$   $f(0) \neq y$  return 0  
 else return 1

Corruption process  $q_D(\tilde{x}|x)$

$$g^0(x, \tilde{x}, y) = g^0(y, \tilde{x}, x) = g^0(y|\tilde{x}, x) \cdot g^0(\tilde{x}|x) \cdot g^0(x)$$

①  $g^0(y|\tilde{x}, x) = g^0(y|\tilde{x})$  인.  $x$ 는 영향  $x$  (관계  $x$ )

②  $g^0(\tilde{x}|x) = q_D(\tilde{x}|x)$

$\rightarrow g^0(y|\tilde{x})$  에 대해서,  $f_{f(0)}(\tilde{x})|y$  3 표현 가능

결과적으로  $g^0(x, \tilde{x}, y) = \underbrace{g^0(x)}_{\text{input} \rightarrow \tilde{x} \rightarrow y} \cdot \underbrace{q_D(\tilde{x}|x)} \cdot \underbrace{f_{f(0)}(\tilde{x})|y}$  3 표현 가능


$\rightarrow$  explicit 하게 다루지 않음. = implicit  $\checkmark$

$\rightarrow$  Generative modeling 측면에서.

$(x \rightarrow y \rightarrow \tilde{x} \rightarrow \hat{x})$  의 과정. 그러나 현재 관심은  $y$  부터.

$\tilde{x}, y \rightarrow y$  관계  $x$ .)  $\rightarrow$  Deterministic  $\rightarrow$  생성 probability  
 $\rightarrow$  VAE의 등장

### Manifold learning perspective



(이 블록은 blank)

$x$  (uncorrupted) 이 corrupt  $\tilde{x} = x$

$\tilde{x}$  는 실제와 다를 때  $x$  은  $\tilde{x}$  (manifold 밖에 있다)

즉,  $p(x|\tilde{x})$  을 구하는 과정을 여러 step이 필요.

$\Rightarrow$  manifold learning stage 포함.

(블록)

### Top-down Generative model perspective

$x \rightarrow \bar{x} \rightarrow y$  이 여러 단계.

$y \rightarrow \bar{x} \rightarrow x : p$  explicit 하므로 문제가 많이 발생함