

## Paper summary

AI VISION Lab

1. 공부한 논문의 제목, 게재된 학회 혹은 저널 등 논문 기본 정보를 적으세요.
  - A. 이름: A Connection Between Score Matching and Denoising Autoencoders
  - B. 저널: Neural Computation
  - C. 도메인: Score matching, DAE(Denoising Autoencoder)
  - D. 출판연도: 2010
  - E. 저자: Pascal Vincent
2. 논문에서 제안한 알고리즘 및 프레임워크에 대해 본인이 이해한대로 다이어그램을 그려보세요. **논문 Figure를 그대로 따라 그리면 안됩니다.**
  - A. [선행연구] Score Function의 역할: gradient of log density에 대해서  $\text{model}(p(x; \theta))$  과  $\text{data}(q(x))$ 의 차이를 줄이도록 설계됨. 이때 가장 중요한 부분은,  $p(x; \theta)$ 를 표현하는데  $z(x)$ 를 구하는 것이 불가능하다는 점인데, 이는  $\text{gradient} + \delta\theta$ 처리를 해주는 과정에서 삭제된다는 장점이 있음.
  - B. [선행연구] 이러한 개념을 가지고, 이전 연구에서는, ISM(Implicit Score Matching) 방식과, ESM(Explicit Score Matching) Objective Function을 제안함. 이는 Denoising 관점에서 일반적인  $X$ : input 만 처리할 수 있다는 한계를 가짐. 또한, 기존 연구에서 계속해서  $X$ : input이 아닌,  $\hat{x}$ : input으로 사용할 때 성능이 높게 나온다는 점에서,  $X$ 에 Noise를 추가한  $\hat{x}$ 에도 적용가능한 Function의 필요성이 높아짐.
  - C. 이 논문에서는 Denoising Autoencoder에서  $X$ 에 Noise를 추가하는 점에서 아이디어를 가져와서 목적함수를 설계하는데 이용함
  - D. 사실, 구조상 다른 점은  $q(x)$ 가 아닌,  $q_{\sigma}(\hat{x}|x)$ 에 대해서 처리해주고 있다는 점인데,  $\sigma$ 가 여기서 Gaussian을 따른다고 가정하고 전개하고 있기 때문에 상대적으로 쉽게 처리할 수 있음(기존의 DAE에서는 Noise를  $X$ 에 Add해주는 형식이 아닌, Random하게 선택된  $x$ 에 대해서 0으로 바꿔주는 형태였음)
  - E. 뿐만 아니라, Energy Function을 적용한  $p(\hat{x}; \theta)$ 에 대해서도 수식을 증명함에 따라, Energy Based Model 과 Score Function을 결합한 형태의 목적함수를

제안함

F. 최종적으로 본 논문에서는  $ESM_{q_\sigma} \approx ISM_{q_\sigma} \approx DSM_{q_\sigma} \approx DAE_{q_\sigma}$  임을 입증함.  
(노트 내용 참고)

3. 본인이 생각하는 이 논문의 장점이 무엇이라고 생각하나요? **논문 Contribution bullet을 그대로 따라 적으면 안됩니다.**

A. 이 논문이 등장하기 전, 존재하던 SOTA에 대해서 (Kingma and LeCun et al.2010) 단점을 파악하고, 주장하는 근거의 장점을 부각하는 점이 인상깊었음. (Kingma and LeCun 논문의 한계: 미분 2번, Sample(X)에 대해서만 적용 가능. 본 논문이 가지는 우수함: 미분 한 번으로 처리 가능, General한 Objective Function ( $\sigma = 0, X, \sigma > 0, \hat{X}$ . 즉  $\sigma = 0$ 은 특수한 상황)

4. 이 논문을 읽으면서 느낀 점, 혹은 배운 점이 있으면 적어보세요.

A. Score matching에 대한 이해도 향상, 수식 증명과정.

B. SOTA에 해당하는 연구와, 이 논문에서 증명하고자 했던 목표가 달랐으나, 결과적으로 같은 이야기를 하고 있다는 점에서 흥미로웠음.

5. 이 논문의 한계점이 있다면 무엇이라고 생각하나요?

A. Gaussian kernel이 없다면 -> Conditional Distribution을 미분했을 때 처리하는데 상당히 까다로울 수 있음. ( $q(x, \hat{x}) = q(\hat{x}|x) * q(x)$ , 해당 논문에서는  $N(0, I\sigma^2)$ 를 따르는 식에 대해서 처리함. 따라서, 미분 결과가 명확했다는 장점이 있음)

6. 본인의 연구에 접목시켜볼 점이 있을지 생각하고 적어보세요.

A. Diffusion 선행연구

7. 본 Summary를 작성하는 과정에서 생성형AI를 사용했나요?

A. 아니요

날짜: 2025-06-26

이름: 신준원

2025. 06. 26 목요일 A Connection Between Score Matching & DAE

## Energy based model (EBM)

probabilistic  $x \rightarrow$  energy based.

상용라면, energy based 가 왜 필요한가?

softmax  $\rightarrow$  image 사용

목표  $\rightarrow$  observed  $\Rightarrow$  맞은 것 (정답)  
 $\rightarrow$  wrong  $\Rightarrow$  틀린 것 (오답)

이러한 문제 해결 모델 (Generative model)

energy = 적재하지 않은 가중치


$$P = \frac{1}{Z} \cdot g \rightarrow$$

$Z$  = 가능한 것의 총합

$$g = \exp(-E_\theta(x))$$

$E_\theta(x)$  가 작을수록

$E_\theta(x)$  가 작을수록 가중치



## Boltzmann Distribution (= Gibbs Distribution)

$$P_i \propto \exp(-\frac{E_i}{kT})$$

$\rightarrow$   $\propto$  관련

Contrastive Divergence

## Introduction

Score matching의 변형

① Continuous 뿐만 아니라, discrete 한 문제도 적용가능.

Denoising Autoencoder 변형 (with SM - Score Matching)

like DAE

추출생성  $\rightarrow$  input  $x$  (vanilla)의 생성변수 input  $(x + \text{noise})$  생성  $\uparrow$

$\rightarrow$  RBM + SM  $\Rightarrow$  AE 생성과 동일. (GM 사용)

결과  $\rightarrow$  DAE와 ~~같은 것~~ GM을 사용한다면?

정확한  
생성가능성

## Notation

discrete distribution  $\rightarrow$  Dirac-deltas  $\delta$ .

$J_i \sim J_v$ ,  $J_i, J_v \in \mathbb{R}$  중의

$\langle u, v \rangle = \sum_i u_i v_i$  (dot product)



# DAZ + Score Matching

DAZ  $\Rightarrow$  Vanilla version  $\Rightarrow$  Data Blank 224 (Random)  
 $\hookrightarrow$  Noise Addition,  $X + \epsilon \sim \mathcal{N}(0, I_D)$  (noise Addition)

Score Matching = true distribution of  $x(x; \theta)$   $\frac{\partial \log p(x; \theta)}{\partial \theta}$

Energy Based eq.  $p(x; \theta) = \frac{1}{Z(\theta)} \exp(-E(x; \theta))$   
 energy function

Score Matching (ZSM)  $J(\theta) = \mathbb{E}_{g(x)} \left[ \frac{1}{2} \left\| \psi(x; \theta) - \frac{\partial \log g(x)}{\partial x} \right\|^2 \right]$   
 $\hookrightarrow \frac{\partial \log p(x; \theta)}{\partial x}$  ~~True + Noise~~ ~~Score~~  
 data ~~model: p~~

Score Matching (IGM)  $J(\theta) = \mathbb{E}_{g(x)} \left[ \frac{1}{2} \left\| \psi(x; \theta) \right\|^2 + \sum_{i=1}^d \frac{\partial \psi_i(x; \theta)}{\partial x_i} \right] + c.$

$\hookrightarrow g \approx p$   $\hookrightarrow$  implicit  $\hookrightarrow J_{ZSM, g} - J_{IGM, g}$

이 경우에는 finite 224의 data를 사용해서  $\theta$ 를 찾는다

Score Matching (IGM  $g_0$ )  $J(\theta) = \frac{1}{n} \sum_{i=1}^n \left( \frac{1}{2} \left\| \psi(x^{(i)}; \theta) \right\|^2 + \sum_{i=1}^d \frac{\partial \psi_i(x^{(i)}; \theta)}{\partial x_i} \right)$   
 (Score)  $\frac{d}{dx}$

$\frac{1}{n} \sum_{i=1}^n \left( \frac{1}{2} \left\| \psi(x^{(i)}; \theta) \right\|^2 + \sum_{i=1}^d \frac{\partial \psi_i(x^{(i)}; \theta)}{\partial x_i} \right) \xrightarrow{n \rightarrow \infty} \mathbb{E}_{g_0} \left[ \frac{1}{2} \left\| \psi(x; \theta) \right\|^2 + \sum_{i=1}^d \frac{\partial \psi_i(x; \theta)}{\partial x_i} \right]$   
 2.  $\frac{1}{n} \sum_{i=1}^n \left( \frac{1}{2} \left\| \psi(x^{(i)}; \theta) \right\|^2 + \sum_{i=1}^d \frac{\partial \psi_i(x^{(i)}; \theta)}{\partial x_i} \right)$   $\xrightarrow{n \rightarrow \infty}$  IGM  $J - \lim_{n \rightarrow \infty} \text{IGM } g_0$

따라서, (이러한 IGM  $g_0$  가 아닌,  $J_{IGM, \text{reg}}(\theta) < J_{IGM, g_0}(\theta)$   $\hookrightarrow$  Kim et al. (2010))

$J_{IGM, \text{reg}}(\theta) = J_{IGM, g_0}(\theta) + \lambda \sum_{i=1}^d \left( \frac{\partial \psi_i(x^{(i)}; \theta)}{\partial x_i} \right)^2$

# Connecting DAE + SM

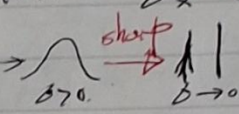
Parzen window density estimator (with  $u^m$ )

(non-parametric)

observed data sample을 가지고  $p(x)$  추정하는 방법.

$$p(x) = \frac{1}{n} \sum_{i=1}^n K_{\delta}(x - x_i) \quad (K_{\delta} = \text{kernel / kernel})$$

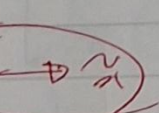
Score function  $S(x)$ . objective  $J_{\text{SM}}(\theta) = E \left[ \frac{1}{n} \left\| \psi(\tilde{x}; \theta) - \frac{\partial \log q_{\theta}(\tilde{x})}{\partial \theta} \right\|^2 \right]$

( $\delta > 0$ ,  $\delta \rightarrow 0$ ,  $\delta \rightarrow 0$ ,  $\delta \rightarrow 0$ ,  $\delta \rightarrow 0$ )  $\rightarrow$  

## Denoising Score Matching

model.

large  $\delta$

DAE  $\rightarrow$  

$$J_{\text{SM}}(\theta) = E_{q_{\theta}(\tilde{x}, x)} \left[ \frac{1}{2} \left\| \psi(\tilde{x}; \theta) - \frac{\partial \log q_{\theta}(\tilde{x}|x)}{\partial \theta} \right\|^2 \right]$$

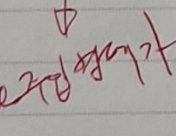
$x \rightarrow \tilde{x}$  가 다른  $\tilde{x}_1, \tilde{x}_2$  등

$\rightarrow$  Gaussian kernel

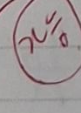
$$\frac{\partial \log q_{\theta}(\tilde{x}|x)}{\partial \tilde{x}} = \frac{1}{\delta^2} (x - \tilde{x})$$

$\delta > 0$  ~~smooth~~  $\rightarrow$  ~~Parzen~~  $\rightarrow$   $\delta \rightarrow 0$

$$J_{\text{SM}}(\theta) \sim J_{\text{SM}}(\theta)$$

noise  $\rightarrow$  

Gaussian



$$J_{\text{SM}}(\theta) = \frac{1}{2} E_{q_{\theta}(\tilde{x}, x)} \left[ \left\| \psi(\tilde{x}; \theta) - \frac{\partial \log q_{\theta}(\tilde{x}|x)}{\partial \theta} \right\|^2 \right]$$

$\delta$



$$\boxed{J_{ESM} = J_{DSM} \quad \text{공명}}$$

$$J_{ESM} = E_{q_\theta(x)} \left[ \frac{1}{n} \left\| \psi(x; \theta) - \frac{\partial \log q_\theta(x)}{\partial \theta} \right\|^2 \right] \quad \text{실제치 (기대)} \\ = E_{q_\theta(x)} \left[ \frac{1}{n} \left\| \psi(x; \theta) \right\|^2 \right] - S(\theta) + C_v \quad (\text{notation error})$$

이때  $C_v = E_{q_\theta(x)} \left[ \frac{1}{n} \left\| \frac{\partial \log q_\theta(x)}{\partial \theta} \right\|^2 \right] \rightarrow \theta$  와 무관한 값

$$S(\theta) = \frac{1}{n} \cdot n \cdot E_{q_\theta(x)} \left[ \psi(x; \theta) \cdot \frac{\partial \log q_\theta(x)}{\partial \theta} \right] = \int q_\theta(x) f_\theta(x) dx = \int q_\theta(x) \log q_\theta(x) dx \\ = \int q_\theta(x) \left[ \psi(x; \theta) \cdot \frac{\partial \log q_\theta(x)}{\partial \theta} \right] dx, \quad \frac{d}{d\theta} \log q_\theta(x) = \frac{\frac{1}{q_\theta(x)} \frac{\partial q_\theta(x)}{\partial \theta}}{q_\theta(x)}$$

$$= \int \left[ \psi(x; \theta) \cdot \frac{\frac{\partial q_\theta(x)}{\partial \theta}}{q_\theta(x)} \cdot q_\theta(x) \right] dx = \int \psi(x; \theta) \cdot \frac{\partial q_\theta(x)}{\partial \theta} dx \\ = \int \psi(x; \theta) \frac{\partial}{\partial \theta} \left( \int q_\theta(x) q_\theta(x|x) dx \right) d\theta \quad \rightarrow q_\theta(x|x) \rightarrow q_\theta(x|x) \text{ marginal distribution}$$

$$\rightarrow \frac{\partial q_\theta(x|x)}{\partial \theta} = \frac{\partial \log q_\theta(x|x)}{\partial \theta} = \frac{1}{q_\theta(x|x)} \cdot \frac{\partial q_\theta(x|x)}{\partial \theta}$$

$$\Rightarrow \frac{\partial q_\theta(x|x)}{\partial \theta} = q_\theta(x|x) \cdot \frac{\partial \log q_\theta(x|x)}{\partial \theta} \quad \psi(x; \theta) \Rightarrow \frac{\partial \log q_\theta(x|x)}{\partial \theta} = \frac{1}{q_\theta(x|x)} \frac{\partial q_\theta(x|x)}{\partial \theta}$$

$$= \int \int q_\theta(x, x) \left( \psi(x; \theta) \cdot \frac{\partial \log q_\theta(x|x)}{\partial \theta} \right) dx \cdot d\theta$$

$$= E_{q_\theta(x, x)} \left( \psi(x; \theta) \cdot \frac{\partial \log q_\theta(x|x)}{\partial \theta} \right) = S(\theta) \quad \text{해당 값을 2)에서 보면}$$

$$J_{ESM} = E_{q_\theta(x)} \left[ \frac{1}{n} \left\| \psi(x; \theta) \right\|^2 \right] - E_{q_\theta(x, x)} \left( \psi(x; \theta) \cdot \frac{\partial \log q_\theta(x|x)}{\partial \theta} \right) + C_v$$

DSM 3 등분하게 설계하면  
(상수  $C_v$ )

$$\boxed{J_{ESM} = J_{DSM} + C_v - C_v}$$

(\*)

→ Energy Based 3 가지, SM은 2가지, 특히 관성/파괴/유지

### Energy Based, Perisiting Autoencoder

$$p(x|\theta) = \frac{1}{Z(\theta)} \cdot \exp(-E(x|\theta))$$

$$\theta = W, b, C$$

Decoder bias

Encoder bias

$$E(x; w, b, C) = -\frac{\langle C, x \rangle - \frac{1}{2} \|x\|^2 + \sum_{j=1}^d \text{softplus}(\langle w_j, x \rangle + b)}{\sigma^2}$$

$$\text{softplus} = \log(1 + e^x)$$

$$\psi_i(x|\theta) = \frac{\partial E}{\partial x_i} = \frac{\partial \log p(x|\theta)}{\partial x_i}$$

에너지 함수에 대해  $x_i$  미분

$C$  = linear attraction

energy  $E$  =  $\frac{1}{2} \|x\|^2$  항

$$\frac{\partial}{\partial x} \text{softplus} = \frac{e^x}{1 + e^x}$$

sigmoid

$$\log(1 + e^x) \rightarrow \frac{e^x}{1 + e^x} = \text{sigmoid}(x)$$

$$\frac{\partial}{\partial x} \left( \frac{C}{\sigma^2} - \frac{1}{\sigma^2} x \cdot x + \sum_{j=1}^d \text{sigmoid}(\langle w_j, x \rangle + b) \right) \frac{w_j}{\sigma^2}$$

$$\frac{\partial}{\partial x} \langle C, x \rangle = C \rightarrow \langle w_j, x \rangle + b \text{ 로 작용}$$

$$\frac{\partial}{\partial x} (C - x + \langle w_j, \text{sigmoid}(w_j x + b) \rangle) = \psi_j(x|\theta)$$

여기서  $\psi_j(x|\theta)$  를  $E_{DSM}$ 에 대입.  $\frac{\partial \log p(x|x)}{\partial x} = \frac{1}{\sigma^2} (x - \tilde{x})$

$$J_{DSM} = E_{p(x, \tilde{x})} \left[ \frac{1}{2} \left\| \frac{1}{\sigma^2} (w^T \text{sigmoid}(w\tilde{x} + b) + C - \tilde{x}) - \frac{1}{\sigma^2} (x - \tilde{x}) \right\|^2 \right]$$

$$= E_{p(x, \tilde{x})} \left[ \frac{1}{2} \left\| \frac{1}{\sigma^2} (w^T \text{sigmoid}(w\tilde{x} + b) + C - \tilde{x} - x + \tilde{x}) \right\|^2 \right]$$

temperature (= noise controller)

$$J_{DAE} = \frac{d}{d\theta} DAE - \text{input} \cdot \text{output}$$

$$J_{DSM} \approx J_{DAE}$$



## Conclusion

650 시 적용.

$J_{Igm\ 86} \sim J_{Egm\ 86} \sim J_{Dgm\ 86} \sim J_{DAZ\ 86}$

① equivalent  $\frac{1}{2}$

② 바뀐 값  $\times J$  시안  $\rightarrow$  바뀐.

③ Energy Based 시안 (Energy J.).

~~④~~