

Paper summary

AI VISION Lab

1. 공부한 논문의 제목, 게재된 학회 혹은 저널 등 논문 기본 정보를 적으세요.
 - A. 이름: **Denoising Diffusion Probabilistic Models**
 - B. 저널: NeurIPS
 - C. 도메인: Diffusion Probabilistic Model
 - D. 출판연도: 2020
 - E. 저자: Jonathan Ho et al.
2. 논문에서 제안한 알고리즘 및 프레임워크에 대해 본인이 이해한대로 다이어그램을 그려보세요. 논문 Figure를 그대로 따라 그리면 안됩니다.
 - A. 해당 논문은 DPM(Diffusion Probabilistic Model)의 형태를 따르고 있음
 - B. [선행연구] DPM에서는 Forward Process, Reverse Process, ELBO 형태의 Loss를 제안했고, DDPM에서는 해당 연구를 기반으로 발전시키는 구조임.
 - C. [선행연구] Forward Process의 경우, Noise를 주입해가는 과정으로, $x_0 \rightarrow x_T$ 결과적으로는 x_0 의 분포를 붕괴시키는 과정임. 이때, Noise는 $\sim N(0, I)$ 를 따르며 $x_T \sim N(0, 1)$ 형태를 만들어 냄.
 - D. [선행연구] Reverse Process의 경우, 앞서 붕괴한 x_T 를 시작으로 x_0 를 Sampling하는 과정을 의미하는데, 해당과정은 Intractable하다보니, Jensen's Inequality 기반의 ELBO 형태로 Loss를 구성해서 학습을 수행함.
 - E. [선행연구] DBM에서는 이 과정을 3가지로 나눠서 계산했는데,
 - i. L0 $p(x_0 | x_1)$ 의 경우, Edge Effect를 고려해서, 고정된 형태로 계산
 - ii. LT $p(x_T)$ 는 Closed Form이기 때문에 계산이 간단함. -> Entropy형태
 - iii. LT-1, 0, T를 제외한 부분으로 ELBO형태
 - F. DDPM: Forward Processing과정의 β 에 대해서 상수항으로 고정(학습X, 뿐만 아니라, 이 형태의 경우, LT은 무시할 수 있음(상수취급)
 - G. $q(x_t | x_0) = N(x_t; \sqrt{\bar{\alpha}}x_0, 1 - \bar{\alpha})$, $x_0 \rightarrow x_t$ 의 Closed Form Distribution 추론
 - H. [표기] $1 - \beta_t = \alpha_t, \bar{\alpha} = \prod_{s=1}^t \alpha_s$

- I. Loss Function: L0의 경우, Edge Effect 로 인해, 학습이 잘못된 방향으로 갈 수 있다는 점을 예방하고자, 실제 상황을 가정하고 실험함. (Image input에 대해서, 각 Pixel 마다 구분해서 값을 구하고 적분하는 형태로 계산) 이때, 결과적으로, 연속적인 분포의 경우와 값이 비슷함을 증명했음. 즉, 이산적인 계산으로 Likelihood 값과 동일함을 보임.
 - J. LT-1의 경우, 기존의 DPM에서 $D_{KL}(q(x_{t-1} | x_t, x_0) || p_{\theta}(x_{t-1} | x_t))$ 를 계산하는 형태로, x_0 를 조건으로 제시해야만, Closed Form형태의 Posterior 값을 구할 수 있었음.
 - K. 이때, DDPM의 경우, 해당 과정을 L2 Loss 형태로 표현할 수 있음을 보임.
 - L. $E_q(\frac{1}{2\sigma^2}[\tilde{\mu}_t(x_t, x_0) - \mu_t(x_t, t)]^2)$
 - M. 여기서 더 나아가, Reparameterization 과정을 결합, Mean에 대한 예측이 아닌, $x_t(x_0, \epsilon) = \sqrt{\alpha}x_0 + \sqrt{1 - \alpha}\epsilon$ 형태를 적용해, x_0 (고정)과 $\epsilon \sim N(0, I)$ 만으로 표현하는 구조를 추론함. 즉(KL Divergence -> Mean -> noise 예측)
 - N. 최종적으로, Simple Loss(L0, LT 삭제 및 시간에 따라 달라지는 noise의 scheduler를 제거한 Loss로, noise의 크기와 상관없이 동일한 Loss 값을 부여하는 구조임) 가 우수함을 실험적으로 보임으로써, 간단한 구조의 Loss Function을 선보임.
3. 본인이 생각하는 이 논문의 장점이 무엇이라고 생각하나요? **논문 Contribution bullet을 그대로 따라 적으면 안됩니다.**
- A. 가장 큰 장점은 Diffusion Loss를 ELBO 형태에서, Epsilon(Noise)를 예측하는 문제로 전환시켰다는 점임. 기존의 DPM 모델의 형태, L0, LT, LT-1을 발전시켰음과 동시에 Simple Loss를 제시했고, 현재 대부분(Hugging Face, GitHub 등)에서는 Simple Loss를 사용하고 있다는 점에서 큰 의미가 있음.
 - B. 뿐만 아니라, $x_t|x_0$ 의 Closed Form을 보여줌으로써, Forward process를 빠르게 통과할 수 있도록 함.
4. 이 논문을 읽으면서 느낀 점, 혹은 배운 점이 있으면 적어보세요.
- A. Reparameterization의 적용과정에 대해서 깊게 파악가능

5. 이 논문의 한계점이 있다면 무엇이라고 생각하나요?

A. 여전히, Reverse process를 $T \sim 1$ (Simple Loss 기준)번 실행해야 한다는 점은 Sampling과정을 오랫동안 기다려야 한다는 단점으로 작용함.

6. 본인의 연구에 접목시켜볼 점이 있을지 생각하고 적어보세요.

A. Diffusion 선행연구

7. 본 Summary를 작성하는 과정에서 생성형AI를 사용했나요?

A. 아니요

날짜: 2025-06-30

이름: 신준원

06/30 denoising Diffusion Probabilistic model

keyword: VI (variational inference), denoising Score matching, Langevin

DPM (Diffusion Probabilistic model) - Nichol et al 2014

- VI (Variational Inference) \rightarrow intractable 한 문제를 해결하기 위한 방법
 \Rightarrow ZLBO 사용
- Markov chain
- finite step.
- forward + reverse.
- noise (to Gaussian)

model probability \rightarrow $p_\theta(x_T) = \mathcal{N}(x_T; 0, I)$ (forward process output)

$p_\theta(x_0) = \int p_\theta(x_0:T) dx_{1:T}$

$p_\theta(x_{t+1} | x_t) = \mathcal{N}(x_{t+1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$ (reverse kernel)

$$E[-\log p_\theta(x_0)] \leq E_q[-\log \frac{p_\theta(0:T)}{q(x_{1:T}|x_0)}] = E_q[-\log p(x_T) - \sum_{t=1}^T \log \frac{p_\theta(x_{t-1}|x_t)}{q(x_t|x_{t-1})}] = L$$

intractable \rightarrow (Jensen's inequality) ZLBO 사용 (negative log likelihood)

★ forward process (β_t)

$\beta_t \rightarrow$ Constant \rightarrow 학습 과정은 β_t reverse process Gaussian noise를 사용.
 $\beta_t \rightarrow$ learning.

$\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$

$$q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I)$$

확률과정

probability

→ $p \rightarrow$ model

일반적인 g 계산 (non-markov) \Rightarrow 계산 불가능

$$p(x_0, x_1, x_2, \dots, x_T) = p(x_0) \cdot p(x_1 | x_0) \cdot p(x_2 | x_1, x_0) \dots p(x_T | x_{T-1}, \dots, x_0)$$

2014 Diffusion \Rightarrow markov process 로 계산. ($x_t \rightarrow x_{t-1}$ 만 필요, 나머지는 상수)

$$p(x_0, x_1, x_2, \dots, x_T) = p(x_0) \cdot p(x_1 | x_0) \cdot p(x_2 | x_1) \dots p(x_T | x_{T-1})$$

$$\text{즉시 } p(x_0, x_1, \dots, x_T) = p(x_0) \prod_{t=1}^T p(x_t | x_{t-1})$$

이제, forward에 $p(x_t | x_{t-1}) \Rightarrow \mathcal{N}(x_t; \sqrt{1-\beta_t} x_{t-1}, \beta_t I)$ 설정함

해당 부분은 backpropa 불가능.

재미 "reparameterization trick" $\rightarrow x_t = \sqrt{1-\beta_t} x_{t-1} + \sqrt{\beta_t}$

2015 Dickstein \rightarrow forwarding 1000 step

2020 Jonathan Ho \rightarrow closed form 증명 $q(x_t | x_0)$

\rightarrow reparameterization trick 활용

$$x_1 = \sqrt{1-\beta_1} \cdot x_0 + \sqrt{\beta_1}$$

$$x_2 = \sqrt{1-\beta_2} \cdot x_1 + \sqrt{\beta_2} \Rightarrow x_2 = \sqrt{1-\beta_2} (\sqrt{1-\beta_1} \cdot x_0 + \sqrt{\beta_1}) + \sqrt{\beta_2}$$

$$\Rightarrow x_2 = \sqrt{1-\beta_2} \cdot \sqrt{1-\beta_1} \cdot x_0 + \sqrt{1-\beta_2} \cdot \sqrt{\beta_1} + \sqrt{\beta_2}$$

$$x_3 = \sqrt{1-\beta_3} \cdot x_2 + \sqrt{\beta_3} \Rightarrow \sqrt{1-\beta_3} \cdot \sqrt{1-\beta_2} \cdot \sqrt{1-\beta_1} \cdot x_0 + \sqrt{1-\beta_3} \cdot \sqrt{1-\beta_2} \cdot \sqrt{\beta_1} + \sqrt{1-\beta_3} \cdot \sqrt{\beta_2} + \sqrt{\beta_3}$$

$$\rightarrow x_t = \sqrt{1-\beta_t} \cdot \sqrt{1-\beta_{t-1}} \dots \sqrt{1-\beta_1} \cdot x_0 + \sqrt{\beta_t} + \sqrt{\beta_{t-1}} \cdot \sqrt{\beta_{t-2}} + \dots \sqrt{\beta_1} \cdot \sqrt{\beta_2} \dots \sqrt{\beta_1}$$

$$\text{notation: } 1-\beta_t = \alpha_t, \quad \bar{\alpha}_t = \prod_{s=1}^t \alpha_s$$

$$\rightarrow x_t = \sqrt{\bar{\alpha}_t} \cdot x_0 + \sqrt{1-\alpha_t} + \sqrt{1-\alpha_t} \cdot \sqrt{1-\alpha_{t-1}} \dots$$

$$x_t = \sqrt{\bar{\alpha}_t} \cdot x_0 + \sqrt{1-\alpha_t} \cdot \prod_{s=1}^{t-1} \sqrt{1-\alpha_s}$$

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{\alpha_t} x_{t-1}, (1-\alpha_t)I)$$

다 Loss function

DBM

앞서 했던 Loss

$$E_{\theta} \left[-\log p(x_T) - \sum_{t=1}^T \log \frac{p_{\theta}(x_{t+1}|x_t)}{p(x_{t+1}|x_{t-1})} \right]$$

↓ 알려진 부분

해당인자를 지우

2014 DBM에서 증명함

$$E_{\theta} \left[\underbrace{D_{KL}(q(x_T|x_0) || p(x_T))}_{L_T} + \sum_{t=1}^T \underbrace{D_{KL}(q(x_{t+1}|x_t, x_0) || p_{\theta}(x_{t+1}|x_t))}_{L_{T-1}} - \log p(x_t|x_0) \right]$$

edge effect 지워 실제 의미 있는 부분은 L_{T-1}

(fact. markov + 식 변형) \rightarrow q_0 Condition.

DBM에서는 $D_{KL} \rightarrow q(x_{t+1}|x_t, x_0) || p_{\theta}(x_{t+1}|x_t)$ 를 직접 비교하는 형제
 방향성 동일 \rightarrow 둘다 reverse 형제.

① markov process 이므로

$$p(x_t|x_{t-1}) = p(x_t|x_{t-1}, x_0) \quad \text{정답 (방향성 지시)}$$

② reverse 한 형제 변형시

$$\begin{aligned} q(x_t, x_{t-1}|x_0) &= q(x_{t-1}|x_t, x_0) \cdot q(x_t|x_0) \\ q(x_t|x_{t-1}, x_0) &= q(x_t, x_{t-1}|x_0) \cdot \frac{1}{q(x_{t-1}|x_0)} \end{aligned} \quad \Delta \text{ 대칭시.}$$

$$q(x_{t-1}|x_t, x_0) = \frac{q(x_t, x_{t-1}|x_0)}{q(x_t|x_0)} \cdot q(x_{t-1}|x_0)$$

③ q_0 필요 이유

$q(x_{t-1}, x_t)$ 를 구할 수 없음 \rightarrow q_0 + q_0 + q_0 Closed-form 형제 계산 가능
 noise x

analytic (음분, 2차) 계산 가능

④ Gaussian distribution of θ

제한 $q(x_{t-1} | x_t, x_0) = q(x_{t-1} | x_t)$ (markov process.)

$$\Rightarrow \frac{q(x_t | x_{t-1}) \cdot q(x_{t-1}, x_0)}{q(x_t | x_0)} \quad \rightarrow 1 - \alpha_t$$

- ① $q(x_t | x_{t-1}) \sim \mathcal{N}(x_t; \sqrt{\alpha_t} x_{t-1}, \beta_t I)$
 - ② $q(x_{t-1} | x_0) \sim \mathcal{N}(x_{t-1}; \sqrt{\alpha_{t-1}} x_0, (1 - \alpha_{t-1}) I)$
 - ③ $q(x_t | x_0) \sim \mathcal{N}(x_t; \sqrt{\alpha_t} x_0, (1 - \alpha_t) I)$
- notation 참고
앞서 제한 라벨

$$\frac{① \times ②}{③} \sim \frac{x_t \cdot x_{t-1}}{x_t} \sim \mathcal{N}(x_{t-1}; \tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t I)$$

normalizing

$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\alpha_{t-1}} \beta_t}{1 - \alpha_t} x_0 + \frac{\sqrt{\alpha_t} (1 - \alpha_{t-1})}{1 - \alpha_t} x_t$$

$$\tilde{\beta}_t = \frac{1 - \alpha_{t-1}}{1 - \alpha_t}$$

DBM 메커니즘...
" 앞 대칭 광 예제

DDPM

Diffusion \rightarrow 제한도 있어 보이니 차이를 보일.

또한, 필수적으로 정해진 값이 있어야 하는 부분도 있음

①, ②, ③

① Variance β_t

\Rightarrow denoising score matching, Diffusion 결합

② model Architecture

③ Gaussian distribution parameterization of the reverse process

\Rightarrow 참고로, 제한 (simple) 한 objective function 제한
(Variational Bound)

Recap) DBM은 $Loss = L_T + L_{T-1} + L_0$ 사용
PDBM은 β_T (noise) fix 형식 $\rightarrow L_T$ 무시

L₀

$$\rightarrow \text{정규분포 } (\mathcal{N}(x_0; \mu_\theta(x_1, 1), \sigma_1^2 \mathbf{I}))$$

fix \rightarrow answer x_0 3.

DDP \rightarrow edge effect ($t=1 \rightarrow \Delta t=0$ process).

DDPM \rightarrow $q_\theta(x_0|x_1)$ 에 대해서 pixel 별, 계산 진행

\rightarrow 정제과정 Scaling X.
noise 추가 X

\rightarrow Variational Bound. \rightarrow lossless code length

\rightarrow 이산적인 \rightarrow 연속적으로.

실리분포 = Continuous X ($[0, 255]$, image)

\rightarrow 픽셀별 계산 \Rightarrow likelihood 증명 (scaling, Jacobian 포함)

L_{T-1} (22쪽 참조)

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

reverse process.

$$\Sigma_\theta(x_t, t) = \sigma_t^2 \mathbf{I} / \sigma_t^2 = \beta_t / \tilde{\sigma}_t^2 = \frac{1 - \bar{\alpha}_t}{1 - \bar{\alpha}_{t-1}} \beta_t$$

복사 비슷한 양

upper bound $\leftarrow x_0 \sim \mathcal{N}(0, 1)$ 일수록 작음

lower bound $\leftarrow x_0 \sim \text{fix}$ 일수록 작음

$$L_{T-1} : E_\theta \left[\frac{1}{2\sigma_t^2} \left\| \tilde{\mu}_t(x_t, x_0) - \mu_\theta(x_t, t) \right\|^2 \right] + C$$

θ 에 대해

μ 에 대해

상수

(double)

$$\rightarrow \mathcal{N}(x_{t-1}; \mu_\theta(x_t, x_0), \Sigma_\theta(x_t, t))$$

forward process posterior mean.

$$\begin{aligned} L_{T-1} - C &= E_{x_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \left\| \tilde{\mu}_t(x_t(x_0, \epsilon), \frac{1}{\sqrt{\alpha_t}} (x_t(x_0, \epsilon) - \sqrt{1 - \alpha_t} \epsilon)) - \mu_\theta(x_t(x_0, \epsilon), t) \right\|^2 \right] \\ &= E_{x_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \left\| \frac{1}{\sqrt{\alpha_t}} \left(x_t(x_0, \epsilon) - \frac{\beta_t}{\sqrt{1 - \alpha_t}} \epsilon \right) - \mu_\theta(x_t(x_0, \epsilon), t) \right\|^2 \right] \end{aligned}$$

