

Paper summary

AI VISION Lab

1. 공부한 논문의 제목, 게재된 학회 혹은 저널 등 논문 기본 정보를 적으세요.
 - A. 이름: **Denoising Diffusion Implicit Models**
 - B. 저널: **ICLR**
 - C. 도메인: **DIFFUSION**
 - D. 출판연도: **2021**
 - E. 저자: **Jiaming Song, Chenlin Meng, Stefano Ermon**
2. 논문에서 제안한 알고리즘 및 프레임워크에 대해 본인이 이해한대로 다이어그램을 그려보세요. 논문 **Figure**를 그대로 따라 그리면 안됩니다.
 - A. [선행연구] GAN은 우수한 Generative model이지만, 학습이 불안정하다는 확실한 단점을 가지고 있음. 따라서 다양한 연구가 지속됨.
 - B. [선행연구] 그렇게 등장한 DDPM(Jonathan Ho), NCSN(Yang Song)의 경우, Sample quality의 경우 GAN 보다 우위에 있을 뿐만 아니라, 학습을 안정적으로 할 수 있다는 장점을 가지고 있음. 그러나 해당 모델들의 단점은 반복적인 과정을 통해 Sampling을 한다는 점임
 - C. [선행연구] GAN은 1Step만에 Sample을 얻지만, NCSN은 20Step(Langevin Dynamics) DDPM은 T=1000 Step이 필요함.
 - D. 본 논문에서는 Markov Process로 이뤄진 구조의 한계라고 가정하고, Diffusion model의 Forward process에 대해서, Non-Markovian Process를 제안함.
 - E. 기존의 모델(DDPM, DPM)에서도 $p(x_{t-1} | x_t)$ 를 해결하기 위해 $q(x_{t-1} | x_t, x_0)$ 를 사용했음. 이 때는 단순히 형태를 변환하고자 x_0 을 이용하였으나, DDIM에서는 DDPM에서 계산적으로(analytic) 보였던, $q(x_t | x_0)$ 을 이용해, $q(x_{t-1} | x_t, x_0)$ 을 Closed Form으로 제안함. 즉, x_{t-1} 의 경우 x_0 에 필수적으로 의존하는 구조를 완성함. (with x_t)
 - F. Non-Markovian Forward Process를 이용, Generative Process에 대해서 재정

의함 ($x_0 \mid x_1$ 의 경우는 여전히 Deterministic Distribution)

- G. 뿐만 아니라, Loss에 대해서, γ 를 통해 Noise를 Scale할 수 있는 L_γ 를 제시함. ($\gamma = 1$, DDPM과 동일. $\gamma = 0$, DDIM-Deterministic과 동일)
 - H. 이는 $\gamma = 1$ 의 경우 DDPM과 DDIM의 Loss가 동일하다는 것이고, DDIM을 실험하기 위해 학습할 필요가 없다는 의미임(실제로 논문에서는 pretrained DDPM을 불러와서 Sampling을 실험함)
 - I. 또한, $1000=T$ 에 대해서, Subset을 구성 ($p_\theta(x_{t-1} \mid x_t)$)를 계산하던 기존의 Process는 너무 오래 걸리므로, $p_\theta(x_{t-1-k} \mid x_t)$ 의 형태로, t 에서 $\rightarrow t-1-k$ 로 뛰어 넘을 수 있는 Closed Form형태를 제시함. (다만, 여전히 성능적으로는 $k=0$ 일 때 가장 우수함)
 - J. ODE(상미분 방정식)와 유사성을 기반으로, x_T ~~만~~으로 $x_T \rightarrow x_0$ 를 가능하게 함.
3. 본인이 생각하는 이 논문의 장점이 무엇이라고 생각하나요? **논문 Contribution bullet을 그대로 따라 적으면 안됩니다.**
- A. Deterministic 한 구조를 제시 (Recover Task에 이점)
 - B. Non-Markovian + Subset을 통한 Sampling 속도 향상의 열쇠를 제시
 - C. Loss는 변경하지 않고도 이용가능(재학습이 필요 없음)
 - D. ODE 형태의 Close Form 제시
 - E. Noise의 영향력을 제어할 수 있음.
4. 이 논문을 읽으면서 느낀 점, 혹은 배운 점이 있으면 적어보세요.
- A. 선행 연구의 문제점을 파악하고 가설을 세우는 것 보다는 이를 논문에 녹여 내는 과정이 더 어려운 과정이 아닌가 싶음.
5. 이 논문의 한계점이 있다면 무엇이라고 생각하나요?
- A. $T=1000$ 을 subset으로 나눠 (S 는 Subset의 길이: 10, 20, 50, 100, 1000)
Sampling을 진행하는 경우, 여전히 S 가 낮은 상황(예: $S=10$ 인 경우, Sampling을 10Step만에 완료)에서는 $S=1000$ 대비 성능이 상당히 낮음. 따라서, Subset의 길이를 짧게 설정했을 경우에도 성능을 좋게 만들 필요 존재.
6. 본인의 연구에 접목시켜볼 점이 있을지 생각하고 적어보세요.
- A. Diffusion 선행연구
 - B. Recovering을 목적으로 하는 경우(예: Cloud – Removal)에는 ODE 형태

(Noise = 0)로 Sampling하는 것이 옳다고 생각함.

7. 본 Summary를 작성하는 과정에서 생성형AI를 사용했나요?

A. 아니요

날짜: 2025-07-01

이름: 신준원

Denoising ^{Diffusion} Implicit model 01/01

Background

GAN: Sampling quality ↑. 2214 학습 못한.

Diffusion NCSN] → Sampling quality ↑. 2214 학습 못한 Sampling.

예시) GAN : 50k → 1분 소요. (72x72)

Diffusion : 50k → 20시간 소요 (96x96)

뿐만 아니라 NCSN → Sampling with annealed Langevin dynamics 사용.

Diffusion (DDPM) → T step 반복 (with markov process)

→ iterative 한 알고리즘 / GAN → 1 step

저작한 양상 Sampling의 원인을 markov process 이 있다고 판단.

DDIM의 α_t 표기 = DDPM의 $\bar{\alpha}_t$

DDPM

objective: maximizing variational lower bound

$$\max_{\theta} \mathbb{E}_{q(x_0)} [\log p_{\theta}(x_0)] \leq \max_{\theta} \mathbb{E}_{p(x_0, x_1, \dots, x_T)} [\log p_{\theta}(0:T) - \log q(x_1:T | x_0)]$$

즉, 분포

$$\text{이때 } q(x_t | x_0) = \mathcal{N}(x_t | \sqrt{\alpha_t} x_0, (1 - \alpha_t) I)$$

$$\hookrightarrow x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

$$\rightarrow (\alpha_T \rightarrow 0) \text{ 으로 보았을 때 } q(x_T | x_0) \sim \mathcal{N}(0, I)$$

$$\hookrightarrow \sqrt{\alpha_t} \sim 0 \text{ 즉, } \alpha_t \rightarrow 0, \quad 1 - \alpha_t = 1 \cdot I = I$$

$$\frac{2}{\epsilon}, p(x^T) \text{ 관련 } \leftarrow \boxed{\sim \mathcal{N}(0, I)}$$

$$\text{Gaussian 분포임을 보임} \Rightarrow \text{이때 } \boxed{\text{Loss}_Y(\epsilon_p)}$$

$$L_Y(\mathbf{z}_\theta) = \sum_{t=1}^T \gamma_t \mathbb{E}_{x_0 \sim p(x_0), z_t \sim \mathcal{N}(0, I)} \left[\left\| \mathbf{z}_\theta^{(t)} (\sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} z_t) - \mathbf{z}_t \right\|_2^2 \right]$$

$\gamma_{1:T}$ 에 의해 결정되는 계수

$\alpha_t \rightarrow$ noise에 따른 Scale weight

ex) $\gamma = 0.5 \rightarrow \gamma_t = \sqrt{t}$

$\gamma = 1 \rightarrow \gamma_t = t$

$\gamma = 0 \rightarrow \gamma_t = 1 \rightsquigarrow$ Deterministic

forward processing with Non-Markovian.

\rightarrow 이미 x_t 를 구한 뒤 현재 Loss 측정

\rightarrow Loss : $q(x_t | x_0)$ 필요.

(sampling) 혹은 ϕ 로 지정한 forward

- 측정 방법 \rightarrow 여러번 반복 외 (Markov chain)

\Rightarrow non-Markov 적용하기.

$$q_0(x_{1:T} | x_0) = q_0(x_1 | x_0) \prod_{t=2}^T q_0(x_t | x_{t-1}, x_0)$$

$$\Rightarrow q_0(x_1 | x_0) \cdot q_0(x_{T-1} | x_T, x_0)$$

forward joint distribution

(x_0 : Condition)

변형 가능한 Condition

$$q(x_1, x_2, x_0)$$

$q(x_{t+1} | x_t, x_0) \rightarrow x_{t-1}$ 생략 with x_t, x_0 \Rightarrow non-Markovian.

$\frac{2}{2}$. 해당 과정은 fully joint forward process $\frac{2}{2}$ non-Markovian 하지 않음.

★ 이미 DDPM, Diststein 모델에서 $q_0(x_{t-1} | x_t, x_0)$ 변형 후 $\frac{2}{2}$

지정 \rightarrow DDPM 모델에서 $\rightarrow q(x_t | x_0)$ or $q(x_{t-1} | x_t, x_0) = q(x_{t-1} | x_t)$

\rightarrow DDIM. x_0 or x_{t-2} sampling이 가능한 probability 지양 \Rightarrow non-Markov.

$$q_0(x_{t-1} | x_t, x_0) = \mathcal{N}(\sqrt{\alpha_{t-1}} x_0 + \sqrt{1 - \alpha_{t-1} - \beta_t} \cdot \frac{x_t - \sqrt{\alpha_t} x_0}{\sqrt{1 - \alpha_t}}, \beta_t^r I)$$

x_{t-1} sampling (forward) $\rightarrow x_0, x_t$ 모두 필요하기 때문 Markov non-Markovian

$\beta \rightarrow$ noise of Control ex) $\beta \rightarrow 0 \Rightarrow$ Stochastic \rightarrow Deterministic!

Generative process

앞서 정의한 non-markovian distribution based

$$q_\phi(x_{t-1} | x_t, x_0)$$

GAN → noise predict

$$\hat{\epsilon}_\theta^{(t)}(x_t) \leftarrow p_\theta(x_{t-1} | x_t)$$

→ $\hat{\epsilon}_t$ (noise) 예측 → $|\hat{\epsilon}_t - x_t| = \text{noiseless image (prediction)}$

$$f_\theta^{(t)}(x_t) = (x_t - \sqrt{1 - \alpha_t} \cdot \hat{\epsilon}_\theta^{(t)}(x_t)) / \sqrt{\alpha_t}$$

$$x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon \quad \epsilon(x_t | x_0)$$

$$\frac{x_0}{\sqrt{\alpha_t}} = (x_t - \sqrt{1 - \alpha_t} \epsilon) / \sqrt{\alpha_t}$$

$f_\theta^{(t)}(x_t) = \text{model prediction}(x_0)$

$$p_\theta^{(t)}(x_{t-1} | x_t) = \begin{cases} \mathcal{N}(f_\theta^{(1)}(x_1), \sigma_1^2 I) & (t=1) \\ q_\phi(x_{t-1} | x_t, f_\theta^{(t)}(x_t)) & (t \neq 1) \end{cases}$$

가장 Loss

$$J_\phi(\epsilon_\theta) = \mathbb{E}_{x_0:T \sim q_\phi(x_0:T)} [\log q_\phi(x_{1:T} | x_0) - \log p_\theta(x_{0:T})]$$

→ ϕ 변화 = 재학습 필요

수정 loss (최적화 ver.)

$$\mathbb{E}_{x_0:T \sim q_\phi(x_0:T)} \left[\log q_\phi(x_1 | x_0) + \sum_{t=2}^T \log q_\phi(x_{t-1} | x_t, x_0) - \sum_{t=1}^T \log p_\theta(x_{t-1} | x_t) - \log p_\theta(x_1) \right]$$

→ 서로 귀의 J는 L_J , $\gamma = \text{특정 값 일때}$ 의미

$$J = L_J + C \quad (C = \text{constant})$$

l_1 $\gamma=1$ → DDPM Loss에 동일.

Sampling from Generalized Generative process

Non markovian Loss L_{θ} $\rightarrow \beta=1 \Rightarrow$ DDPM과 동일
 $\frac{2}{3}$, pre-train 필요 x. (Pre-train DDPM 사용)

Sampling 워크아웃 $L_{\theta} \rightarrow \theta$ 변화해가며 실행가능

DDIM

(앞서 정의한 $q_{\theta}(x_t | x_{t-1}, x_0)$ 이용)

$$x_{t-1} = \sqrt{\alpha_{t-1}} \left(\underbrace{\frac{x_t - \sqrt{1-\alpha_t} \hat{z}_{\theta}(x_t)}{\sqrt{\alpha_t}}}_{\text{predicted } x_0} + \underbrace{\sqrt{1-\alpha_{t-1}-\alpha_t} \cdot \hat{z}_{\theta}(x_t)}_{\text{direction pointing to } x_t} + \underbrace{\beta_t \epsilon_t}_{\text{random noise}} \right)$$

• $\beta_t = \sqrt{\frac{1-\alpha_{t-1}}{1-\alpha_t}} \cdot \sqrt{\frac{1-\alpha_t}{\alpha_{t-1}}}$ $\beta_t = 0$ 일때 \Rightarrow deterministic \star
 $\rightarrow \hat{z}_t = 0$

= Implicit model

(with fixed procedure = Implicit model)

Accelerated Generation process

T steps의 ~~일부~~ 원 = markov process \rightarrow non markovian, 전체
 $\rightarrow q_{\theta}(x_t | x_0)$

forward step은 존재하지 않음

$x_{1:T} \rightarrow$ subset $\{x_{T_1}, x_{T_2}, x_{T_3}\}$ length S
 $T =$ sub sequence of $1:T$

(x) $T = [1, 2]$

$$\begin{bmatrix} q(x_2 | x_1, x_0) \\ q(x_1 | x_2) \end{bmatrix}$$

$x_{T_1}, x_{T_2}, \dots, x_{T_S}$

$$q(x_{T_i} | x_0) = \mathcal{N}(\sqrt{\alpha_{T_i}} x_0, (1 - \alpha_{T_i}) I)$$

\rightarrow Sampling x_0

Relevance to neural ODE

DDIM \rightarrow n_{t-1} sampling : ODE 와 비슷. (2인리 부분 제외법).

$$d\bar{x}(t) = \left(\frac{d_t - \Delta t}{\sqrt{d_t - \Delta t}} = \frac{d_t}{\sqrt{d_t}} \right) + \left(\sqrt{\frac{1-d_t-\Delta t}{d_t-\Delta t}} - \sqrt{\frac{1-d_t}{d_t}} \right) \cdot \epsilon_{\theta}(t) \quad (2)$$

$$\bar{x}(t) = \frac{x_t}{\sqrt{d_t}}, \quad \delta(t) = \sqrt{\frac{1-d_t}{d_t}} \quad (\text{deparameterization})$$

ODE (상미분 방정식)

$$x(t) \rightarrow \frac{dx(t)}{dt} = f(x(t), t)$$

이때 ODE 의 해는 다음과 같음.

우리에미 주어진 값은 initial condition $x(t_0)$, $f(x(t), t) \rightarrow x(t)$ 는 ?

$$x(t_0 + \Delta t) = x(t_0) + \int_{t_0}^{t_0 + \Delta t} f(x(t), t) dt$$

↓
적분 어려움.

$$f(x(t), t) = \frac{x(t+\Delta t) - x(t)}{\Delta t} \Rightarrow \Delta t \text{ step.}$$

0 Euler method.

$$\rightarrow x(t_{k+1}) = x(t_k) + f(x(t_k), t_k) \Delta t \quad \Delta t+1 \text{ step 예상}$$

- 연속 & δ 와 π 는 t 에 대한 함수

- $\delta(0) = 0$

$$d\bar{x}(t) = \epsilon_{\theta}(t) \left(\frac{\bar{\pi}(t)}{\sqrt{d^{n+1}}} \right) \cdot d\delta(t) \rightarrow \pi_T \text{ 만으로 sampling 가능.}$$

$$= \text{probability flow ODE (VF)}$$

Experiments

τ, σ 변화시키며 실험 진행 (τ_i 에 대한 sigma 값)

$$\sigma_{\tau_i}(\eta) = \eta \sqrt{(1 - \alpha_{\tau_{i-1}})/(1 - \alpha_{\tau_i})} \sqrt{1 - \alpha_{\tau_i}/\alpha_{\tau_{i-1}}}$$
$$+ \hat{\sigma} = \sqrt{1 - \alpha_{\tau_i}/\alpha_{\tau_{i-1}}}$$

- DDPM ($\eta = 1$)

- DDIM ($\eta = 0$) \Rightarrow deterministic

FID 기준 $\rightarrow \downarrow (\tau_i \text{ length}) \uparrow$ 성능 좋음.

\rightarrow 0.0 (deterministic) 할수록 더 높은 성능.

⊕ \downarrow 보다, \uparrow 개수 성능 높음 (12m sample 결과 \downarrow)

결론. step (computation) 이 높을수록 성능 향상 (Trade-off)

DDIM \rightarrow Deterministic \rightarrow 권장하는 결과