

Paper summary

AI VISION Lab

1. 공부한 논문의 제목, 게재된 학회 혹은 저널 등 논문 기본 정보를 적으세요.
 - A. 이름: **Score-Based Generative Modeling Through Stochastic Differential Equations**
 - B. 저널: **ICML**
 - C. 도메인: **Score-based Generative model**
 - D. 출판연도: **2021**
 - E. 저자: **Yang Song, Sohl-Dickstein, P. Kingma, Kumar, Ermon, Poole**
2. 논문에서 제안한 알고리즘 및 프레임워크에 대해 본인이 이해한대로 다이어그램을 그려보세요. **논문 Figure를 그대로 따라 그리면 안됩니다.**
 - A. [선행연구] SMLD(Score-Matching Langevin Dynamics)의 경우, Score Matching을 기반으로 하는 Loss를 사용. 또한, 학습한 Model을 기반으로, Annealed Langevin Dynamics를 통한 Sampling으로 구성.
 - B. [선행연구] DDPM의 경우, Score-matching을 사용한다고 명시적으로 설명하지는 않고 있으나, Log-likelihood를 구하는 Diffusion model의 특성상, Score-Matching의 형태와 비슷한 구조를 가지고 있음.
 - C. 이 논문에서는 두 선행연구를 Score-Matching Based Generative model이라 이야기하되, Noise를 추가/제거하던 과정이 이산적이었던 것을 (1, 2, 3, ..., N) SDE(Stochastic Differential Equations)기반의 형태로, 연속적으로 표현하고자 함. 뿐만 아니라, 두 모델에서 동시에 사용하던 Score Matching을 기준으로, 두 가지 형태의 Noise 주입 형태(VE/VP)를 제안함.
 - D. $p(x_t | x_{t-1})$ 의 형태처럼, $t-1 \rightarrow t$ 형태의 Forward Process를 Discrete model의 특징이라고 이야기 했을 때, 우리는 이것의 분포를 정확하게 표현할 수 있음(Gaussian Distribution). DDPM논문에서는 해당 Distribution을 Reparameterization하여, Diffusion항과, x_{t-1} 을 scaling하는 항(고정)으로 구성했다면 본 논문에서는 이를 Drift항과 Diffusion항으로 구성함(Ito Process).
 - E. $t-1 \rightarrow t$ 의 형태를, $t-\delta x \rightarrow t$ 로 근사함으로써, 연속적인 분포를 따르도록

했고, 결과적으로 SDE를 해결하고자 적용되었던 다양한 solver(e.g., Euler-Maruyama)를 사용할 수 있는 Framework를 사용할 수 있게 됨.

- F. Forward process뿐만 아니라, 선행연구 (1982, Anderson)에서 제시된, Reverse Diffusion 수식을 적용할 수 있게 됨으로써, 기존의 Reverse Process 역시 SDE형태로 해결할 수 있게 됨.
 - G. 또한, 선행연구 SMLD, DDPM의 서로 다른 Noise 주입과정에 대해서, 다른 형태의 SDE 수식을 보임. 이는, VE, VP 뿐만 아니라, 추가적인 SDE가 Diffusion 과정에 적용이 가능함을 의미함.
 - H. 심지어 Sampling과정에서 SMLD: Annealed Langevin Dynamics, DDPM: Ancestral Sampling의 형태로 고정된 구조가 아닌, PC sampling 형태를 제시함으로써, 원하는 SDE-Solver로 Sampling 함수를 변경할 수 있는 확장성 있는 구조를 제시함.
 - I. 결과적으로는, 확장성 뿐만 아니라, 성능의 향상까지 기여했다는 점에서 이 논문은 큰 의미가 있다고 할 수 있음.
3. 본인이 생각하는 이 논문의 장점이 무엇이라고 생각하나요? **논문 Contribution bullet을 그대로 따라 적으면 안됩니다.**
- A. **확장성. SDE를 결합함으로써, 기존에 존재하던 하나의 길이 아닌, SDE의 어떤 함수라도 적용할 수 있는 Framework를 제시했다는 점이 이 논문의 최대 장점이라 할 수 있음.**
4. 이 논문을 읽으면서 느낀 점, 혹은 배운 점이 있으면 적어보세요.
- A. 현 시점의 논문을 이해하는데 큰 도움이 될 것이라 판단됨.
5. 이 논문의 한계점이 있다면 무엇이라고 생각하나요?
- A. 확장성은 제시했으나, 다양한 SDE를 활용해 실험하는 과정이 상대적으로 부족함.
6. 본인의 연구에 접목시켜볼 점이 있을지 생각하고 적어보세요.
- A. Diffusion 선행연구

7. 본 Summary를 작성하는 과정에서 생성형AI를 사용했나요?

A. 아니요

날짜: 2025-07-03

이름: 신준원

07/03 Score-based Generative modeling Through Stochastic Differential Equations

Introduction

x (input) + 순차적인 noise 주입 과정 (주입)
 주입된 noise 을 예측/제거 하는 과정
 → DDPM, GMLD (= NCNLS)
 = 무한한 step을 요인 Generative models

① SMLD (= NCNLS)

→ 각 이미지 에 대한 Score function (= Score 추정)
 ⇒ each noise scale ($x_0 + \epsilon_1 = x_1 \rightarrow x_0$ Score, x_1 Score, x_2 Score, ..., x_n Score)
 → input 1개 다양한 step / 모든 step score estimation (with Score function)

→ Langevin dynamics 3 sampling 진행

$$x_{k+1} = x_k + \frac{\epsilon}{\gamma} \underbrace{\nabla_x \log p(x_k)}_{\text{Score function}} + \sqrt{\epsilon} \cdot z_k \quad z_k \sim \mathcal{N}(0, I)$$

Langevin dynamics ⇒ $\frac{\epsilon}{\gamma}$ Score function 가변의 경우 → 결과로 x_{k+1} sampling 됨.

② DDPM

→ forward step 과정의 noise 추정

→ 이를 역방향으로 reverse ($p_\theta(x_{t-1} | x_t)$) 에 대한

closed-form 제시 + 해결.

이때 DDPM ⇒ Score function 을 계산. (implicit)

↳ log-likelihood 형의 계산. = $\nabla \log p_\theta(x)$!.

결론

DDPM ⇒ implicit 한 Score-function 이용
 SMLD ⇒ explicit 한 Score-function 이용
 둘 다 사용하는 SDE를 사용한 SBM (Score-based-model) 은 최단점
 통합된 권리

~~본 문헌에서는 두 SBM (DDPM, SMLD)를 통합하고 SDZ를~~

SDZ 기반의 SBM — 다중분포.

with GDE, $\text{data} \cdot x$
A

과거 방법 (DDPM, SMLD)

— 분산축약인 noise 주입 $\Rightarrow (i = \text{integer}, x_i, x_{i+1}, \dots) \rightarrow \text{변수}$

새로운 제안 With GDE

— 변형된 구조 제안.

\rightarrow Sample Generation 과정을 smooth 하게

\rightarrow time(±)에 의존하는 구조.

\Rightarrow reverse process에 필요한 정보 from (forward SDZ의 marginalize)

\Rightarrow Sampling에 다양한 SDZ 기법 적용가능

⊕ Contributions

- ① flexible sampling with & log-likelihood computation
- ② Controllable generation
- ③ Unified - framework

Background

① SMLD (=NCSN)

- perturbation kernel (= forward kernel)

$$p_\theta(\tilde{x}|x) = \mathcal{N}(\tilde{x}; x, \sigma^2 I), \quad p_\theta(\tilde{x}) = \int p_{\text{data}}(x) \cdot p_\theta(\tilde{x}|x) dx$$

$$\rightarrow \tilde{x} = x + \sigma I, \quad (\sigma_{\min} = \sigma_1 < \sigma_2 < \dots < \sigma_N = \sigma_{\max})$$

$$p_{\sigma_{\min}}(x) \approx p_{\text{data}}(x)$$

$$p_{\sigma_{\max}}(x) \approx \mathcal{N}(x; 0, \sigma_{\max}^2 I)$$

- optimizer

$$\rightarrow \sigma_i^2 \propto \frac{1}{\mathbb{E}[\|\nabla_x \log p_{\sigma_i}(\tilde{x}|x)\|_2^2]}$$

$$\theta^* = \arg \min_{\theta} \sum_{i=1}^N \sigma_i^2 \mathbb{E}_{p_{\text{data}}(x)} \mathbb{E}_{p_{\sigma_i}(\tilde{x}|x)} \left[\|\nabla_{\tilde{x}} \log p_{\sigma_i}(\tilde{x}|x) - \nabla_x \log p_{\sigma_i}(\tilde{x}|x)\|_2^2 \right]$$

- Sampling (Langevin dynamics)

$$x_i^m = x_i^{m-1} + \epsilon_i \nabla_{\tilde{x}} \log p_{\sigma_i}(\tilde{x}|x) + \sqrt{2\epsilon_i} \tilde{z}_i^m, \quad m = 1, 2, \dots, M$$

$$\begin{aligned} \rightarrow i=1 & \text{ 1/200, 1M번} \\ i=2 & \text{ 1/100, 1M번} \\ & \vdots \\ i=N & \text{ 1/20, 1M번} \end{aligned}$$

$$\tilde{z}_i \sim \mathcal{N}(0, I)$$

$$\begin{aligned} & \text{1x1M번씩} \Rightarrow x_0^0 \sim \mathcal{N}(x|0, \sigma_{\max}^2 I) \\ & x_i^0 = x_{i+1}^M \end{aligned}$$

② DDPM

- forward process

$$P(x_i | x_{i-1}) = \mathcal{N}(x_i; \sqrt{1-\beta_i} x_{i-1}, \beta_i I)$$

$$p_{\alpha_i}(x_i | x_0) = \mathcal{N}(x_i; \sqrt{\alpha_i} x_0, (1-\alpha_i)I), \quad \alpha_i = \prod_{j=1}^i (1-\beta_j)$$

$$p_{\alpha_i} = \int p_{\text{data}}(x) p_{\alpha_i}(\tilde{x} | x) dx$$

$$x_T \sim \mathcal{N}(0, I)$$

- reverse process

$$p_{\theta}(x_{i-1} | x_i) = \mathcal{N}(x_{i-1}; \frac{1}{\sqrt{1-\beta_i}} (x_i + \beta_i s_{\theta}(x_i, i)), \beta_i I)$$

- optimizer (L simple) $\rightarrow (1-\alpha_i) \propto \frac{1}{\mathbb{E}[\|\nabla_x \log p_{\alpha_i}(\tilde{x} | x)\|_2^2]}$

$$\theta^* = \arg \min_{\theta} \sum_{i=1}^N \frac{(1-\alpha_i) \mathbb{E}_{p_{\text{data}}(x)} \mathbb{E}_{p_{\alpha_i}(\tilde{x} | x)} \left[\|s_{\theta}(\tilde{x}, i) - \nabla_{\tilde{x}} \log p_{\alpha_i}(\tilde{x} | x)\|_2^2 \right]}{\mathbb{E}[\|\nabla_x \log p_{\alpha_i}(\tilde{x} | x)\|_2^2]}$$

(등일) *

- Sampling $\approx x_T$. (DDPM에 x_0 주어, $\text{DDIM} \Rightarrow x_T$) \rightarrow closed form로 계산 가능.

input: $x_N \sim \mathcal{N}(0, I)$.

$$x_{i-1} = \frac{1}{\sqrt{1-\beta_i}} \cdot \underbrace{(x_i + \beta_i s_{\theta^*}(x_i, i))}_{\text{trained model}} + \sqrt{\beta_i} z; \quad i = N, N-1, \dots, 1.$$

x_i : input, x_{i-1} : output \Rightarrow [on cestral sampling]

SBM with SDZs

목표 : 연속적인 과정. (x_1, x_2, \dots 가 아닌 $x(t)$)

→ 주어진 dataset

→ P_0 = data distribution

P_1 = prior distribution

$I \pm \hat{\sigma}$ SDZ

$$dx = \underbrace{f(x,t)dt}_{\text{drift}} + \underbrace{g(t)dW}_{\text{diffusion}}$$

= Brownian motion

→ Wiener process

→ vector-valued

Scalar function

$$x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon$$

Drift function / diffusion function

Q) SDZ process 표현을 할 수 있는 장점

* ① 연속적인 forward process

* ② Stochastic 한 random function의 움직임을 deterministic하게 표현가능

→ State(i), time(t) 가 Lipschitz 조건을 만족하는 경우,

$$\left(\|f(x,t) - f(y,t)\| \leq L \|x - y\| \quad \text{모든 } x, y, t \text{에 대해} \right)$$

$$\frac{2}{L}, L \geq \frac{\|f(x,t) - f(y,t)\|}{\|x - y\|}$$

*

$$x_t = \sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \epsilon$$

$$f(x,t) = \sqrt{1 - \beta_t} x_{t-1}, \quad g(t) = \sqrt{\beta_t} \epsilon$$

$$x_t = \frac{f(x,t)}{g(t)}$$

→ a, b 에 대하여 Lipschitz 조건 만족함

$$\|f(a) - f(b)\| = \|\sqrt{1 - \beta_t} a - \sqrt{1 - \beta_t} b\|$$

$$= \sqrt{1 - \beta_t} \|a - b\| \quad \sqrt{1 - \beta_t} \leq \text{우변 값} \quad (\beta_t \rightarrow f(x))$$

Generate samples by reversing SDE

denote as..

$$P_t(x) = X(t)$$

$$P_{t|s}(x(t)|x(s)) = \text{kernel}(S \rightarrow t)$$

$$S_\theta(x,t) = \nabla_x \log P_t(x)$$

$x_T \rightarrow x_0$ (sample).

$$dx = [f(x,t) - f(t)^2 \nabla_x \log P_t(x)] dt + g(t)dw \quad (\text{by Anderson 1992})$$

$$\Rightarrow S_\theta^*(x,t)$$

backward Wiener process

Reverse Diffusion SDE negative timestep

Estimate Scores for the SDE

일반화, Score of model $(= \nabla_x \log p_\theta(x))$ 는 계산 불가능

$$\theta^* = \arg \min_{\theta} \mathbb{E}_{\lambda(t)} \mathbb{E}_{x(0)} \mathbb{E}_{x(t)|x(0)} \left[\|S_\theta(x(t),t) - \nabla_{x(t)} \log p_{\theta_t}(x(t)|x(0))\|_v^2 \right] \quad \text{비용}$$

positive weight function $\Rightarrow \delta_i^2$ or $(1 - \alpha_i)$

Continuous = discrete

$$\lambda \propto \frac{1}{\mathbb{E}[\|\nabla_{x(t)} \log p_{\theta_t}(x(t)|x(0))\|_v^2]}$$

$$\left(\begin{array}{l} \lambda \rightarrow 0 \neq \pm \\ \text{모델 모델} \rightarrow \text{이산적인 것} \quad \pm \rightarrow \pm+1 \quad \text{중요} \\ \text{현재 SDE based} \rightarrow 0 \rightarrow \pm \quad \text{중요} \end{array} \right)$$

이렇다면 해당 kernel 은 어떻게 구하는가?

\rightarrow (kernel 01)

$\rightarrow f(\cdot, t)$ 가 affine $\{y = at + b\}$ 형태면 = Gaussian 분포

\rightarrow closed form

(+)

후, Kolmogorov's forward equation 사용

후, $p_{\theta_t}(x(t)|x(0))$ sample 하기

SDE 풀기

후, sliced Score matching 사용 $\Rightarrow \nabla_{x(t)} \log p_{\theta_t}(x(t)|x(0))$ 계산 기법...

SDE \Rightarrow 다양한 function의 학습이 가능해짐!

* Diffusion Bridge 기호 나열 내용

VZ, VP and Beyond.

① SALD (VE)

perturbed kernel

$$X_t = X_{t-1} + \sqrt{\delta_t^v - \delta_{t-1}^v} Z_{t-1}, \quad t=1, \dots, N.$$

- $\delta_0 = 0$, $Z_{t-1} \sim \mathcal{N}(0, I)$

- $N \rightarrow \infty$, $\{\delta_t^v\}_{t=1}^N \rightarrow \delta(\cdot)$, $Z(\cdot)$ = 연속

- Markov chain \rightarrow Continuous Stochastic process 변화.

$$dX = \sqrt{\frac{d[\delta(t)]}{dt}} dW, \quad \{X(t)\}_{t=0}^1 \text{ 일지.}$$

$X(\cdot) \neq$ 고정, $\delta(t)$ diffusion 변. = VE (variance exploding)

② DDPM (VP)

$$X_t = \sqrt{1 - \beta_t} \cdot X_{t-1} + \sqrt{\beta_t} \cdot z_{t-1}, \quad t = 1, \dots, N.$$

$\beta_t \rightarrow \beta(t), z_{t-1} \rightarrow z(t) = \text{"噪声"}$

$i-1 \text{ to } i / i-\Delta t \text{ to } i / i \text{ to } i+\Delta t$

derivation) $X(t+\Delta t) = \sqrt{1 - \beta(t+\Delta t)} X(t) + \sqrt{\beta(t+\Delta t) \Delta t} z(t)$

1차 근사 $X(t+\Delta t) \approx X(t) - \frac{1}{2} \beta(t+\Delta t) \Delta t X(t) + \sqrt{\beta(t+\Delta t) \Delta t} z(t)$

0차 근사 $X(t+\Delta t) \approx X(t) - \frac{1}{2} \beta(t) \Delta t X(t) + \sqrt{\beta(t) \Delta t} z(t)$

$dx = -\frac{1}{2} \beta(t) x dt + \sqrt{\beta(t)} dw$

Δt 무한소

fixed variance \rightarrow VP (variance preserving)

③ Sub-VP SDE (제한된 4차 SDE)

$$dx = -\frac{1}{2} \beta(t) x dt + \sqrt{\beta(t) \left(1 - e^{-2 \int_0^t \beta(s) ds}\right)} dw$$

- VP 와 동일한 $\beta(t)$ 사용

- $\sqrt{\beta(t)}$ ($t=0$) 를 상수로 제한 (1차 sub-VP)

Solve the reverse SDE

model training 라운드 \rightarrow sampling! (x_0)

\sim from p_0

- Euler-Maruyama
- Stochastic Runge-Kutta method
- Ancestral sampling
- etc (다른 SDE 해결방안도 꽤 적용가능)

Predictor-Corrector

일반적인 SDE

+
SDE의 샘플 \Rightarrow MCMC 적용 편리

\hookrightarrow Sampling (from p_t) \Rightarrow (다음은) SDE 해결방안에서 나온 해를 보낼 수 있음.
one step

Predictor: SDE solvers

Corrector: any score-based MCMC approach.

즉, predictor가 생성한 sample 기반 distribution

\hookrightarrow Corrector가 check

결과 \Rightarrow PC-sampler 성능 ↑

Probability flow & ODE

GDZ와 같은, ~~정확한~~ deterministic한 ODE \rightarrow 모든 diffusion process에 존재.

$$dx = \left[f(x, t) - \frac{1}{2} g(t)^2 \nabla_x \log p_t(x) \right] dt - \boxed{dw x}$$

\rightarrow probability flow ODE.

\rightarrow GDZ와 같은 흐름, but deterministic.

ODE가 가지는 장점

- Random x.

\rightarrow 정확한 likelihood 계산 \rightarrow 결과 증명.

\rightarrow Image editing, interpolation, temperature Scaling 사용가능